


חלק מעשי:

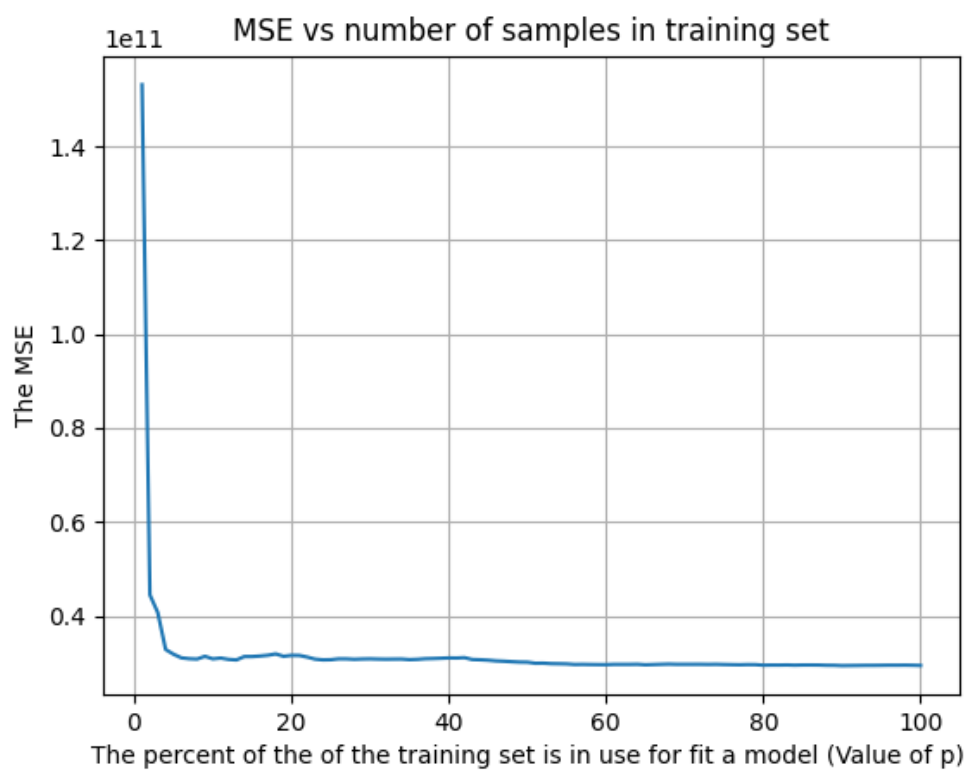
13. תכונת ה-ZIPCODE היא תכונה קטגורית מכיוון שזה כתובת מתוך מרחב כתובות מוגדר של הקודים באותה מדינה. בנוסף זו תכונה בעלת ערך מספרי אך שאינו בכל יחס סדר טבעי שכן מדובר בכתובות שרירותיות, אבל יש להניח כי הוא עלול כן להשפיע על המחיר שכן הוא מקודד את מיקום הנכס ולכן בחרתי בגישה ה-"HOT 1" וכך באמת ניתן יהיה לגלות קורולציות בין כתובות שונות למחיר

15. ניתן לראות מהגרף שהערכים הסינגולריים שואפים לאפס ככל שהאינדקס גדל אך אף אחד מהם אינו 0, מכאן ניתן להסיק שהמטריצה XX^T היא מטריצה "כמעט" סינגולרית



.16

ניתן ללמוד מהגרף שהשגיאה הממוצעת הריבועית מתקרבת לאפס ככל שמספר הדגימות (אחוז) גדל
זאת משום שככל שיש יותר דגימות האומדנים משתפרים (חוקי סטטסטיקה)



תרגיל בית 2 IML

דורון ברודר
204917629
doronbruder

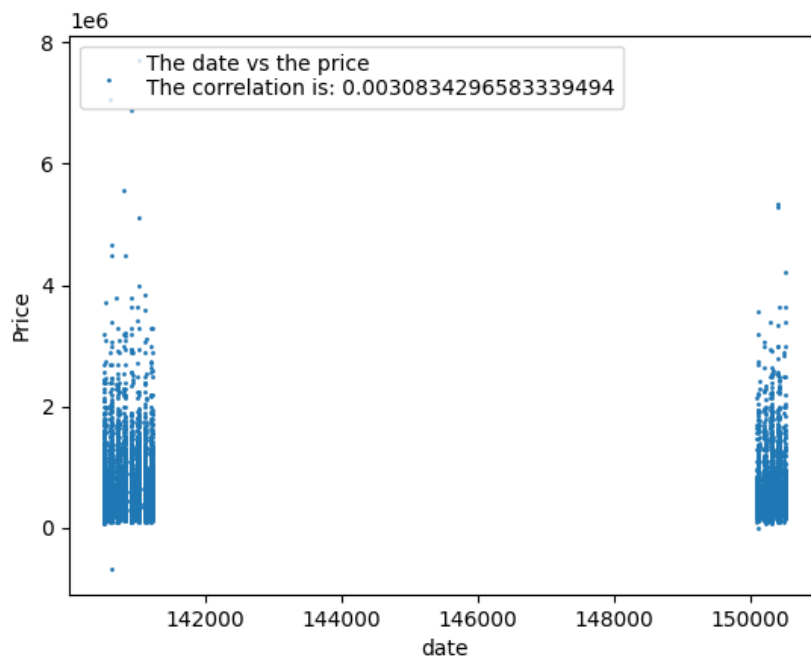
17.

התכונות הלא קטגוריות הן:

```
date', 'sqft_living', 'sqft_lot', 'floors', ']  
, 'sqft_above', 'bathrooms', 'bedrooms  
sqft_basement', '  
['yr_built', 'yr_renovated', 'sqft_living15', 'sqft_lot15
```

שכן התכונות הנ"ל (באופן תאורטי) לא חסומות וכל ערך שלם יכול להיות ערך חוקי עבורן, בניגוד למשל לVIEW שהוא ערך בינארי, או ערכים אחרים שהושמטו. נציג כעת את הגרפים השונים:

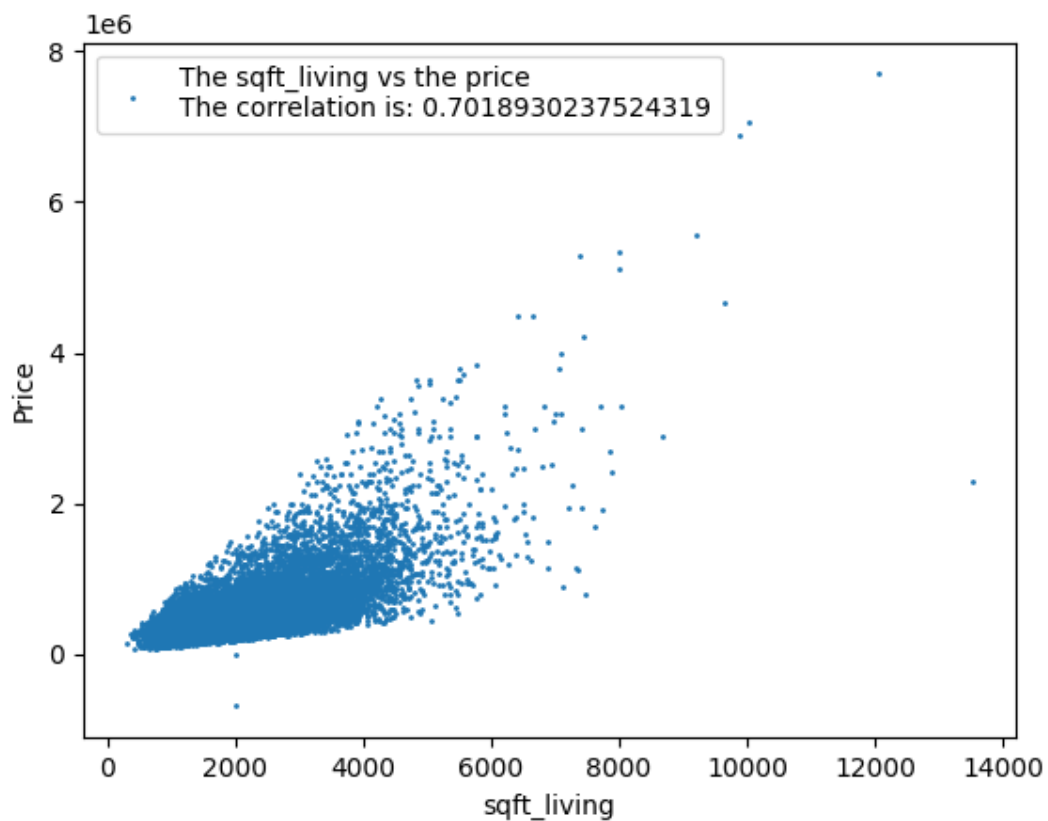
נתחיל בגרף של פיצ'ר שלא משפיע על המודל: התאריך פרסום של המודעה (DATE) ניתן להבין שזו תכונה לא מועילה מכיוון שיש ריכוז זה של מחירים שונים גם בתאריכים ישנים וגם בתאריכים חדשים (בקצוות)



תרגיל בית 2 IML

דורון ברודר
204917629
doronbruder

כעת נציג גרף של פיצ'ר שנראה כמשפיע על המודל : גודל הסלון (sqft_living) ניתן להבין כי זה משפיע על המודל , כלומר על המחיר שכן החל ממחיר מסויים ניתן לראות שבהכרח יש רק חדרי סלון שגודלים מגודל מסויים , למשל מעל 4 מליון הסלון בהכרח מעל 6000



[T: V → V הפונקציה הליניארית X היא A על V ו- X^T היא A^T על V]

: 1.1

$$\ker(X) = \ker(X^T X) : \text{ס.3 (1)}$$

(נניח V הוא מרחב וקטורי)

$$\text{נניח } Xv = 0 \quad \text{כל } v \in \ker(X) \quad \text{אז} \quad \Rightarrow$$

$$X^T X v = X^T (X v) = X^T 0 = 0$$

$$v \in \ker(X^T X) \quad \text{כל}$$

$$(X^T X)v = 0 \quad \text{כל } v \in \ker(X^T X) \quad \text{אז} \quad \Rightarrow$$

$$\text{נניח } v^T = 0 \quad \text{כל}$$

$$v^T X^T X v = 0$$

$$\Rightarrow (Xv)^T (Xv) = 0$$

$$\Rightarrow \langle Xv, Xv \rangle = 0$$

$$\Rightarrow Xv = 0$$

$$\Rightarrow v \in \ker(X)$$

$$\text{Im } A^T = (\ker(A))^\perp : \text{ס.3 (2)}$$

(הוכחה: A היא פונקציה ליניארית מ- V ל- W)

$$A^T x = b \quad \text{כל } x \in V \quad \text{כל } b \in \text{Im } A^T \quad \text{אז} \quad \Rightarrow$$

$$Av = 0 \quad \text{כל } v \in \ker(A) \quad \text{אז}$$

$$\langle b, v \rangle = \langle A^T b, v \rangle = \langle b, Av \rangle = \langle b, 0 \rangle = 0$$

$$\Rightarrow b \in (\ker(A))^\perp \Rightarrow \text{Im}(A^T) \subset (\ker(A))^\perp$$

$$\text{כל } b \in (\ker(A))^\perp \Rightarrow \text{Im}(A^T) \supset (\ker(A))^\perp$$

לכן $\text{Im}(A^T) = (\ker(A))^\perp$

$$\dim \text{Im } A^T = \dim \text{Im } A = \dim V - \dim \ker A$$

$$\dim(\ker A)^\perp = \dim V - \dim \ker A \Leftrightarrow \dim V = \dim \ker A + \dim(\ker A)^\perp$$

$$\text{Im } A^T = (\ker(A))^\perp \quad \text{כל}$$

1.1 תרגיל:

(3) A הוא מטריצה $n \times m$ ו- $b \in \mathbb{R}^n$ ו- $x \in \mathbb{R}^m$ הם וקטורים.
 נניח ש- $b \in \text{Im}(A)$.
 הראה ש- $x \in \ker(A) \iff x \in \text{Im}(A^T)$

$$y \perp \ker(A) \iff y \in (\ker(A))^\perp \iff y \in \text{Im}(A^T)$$

כל $y \in \text{Im}(A^T)$ הוא צירוף ליניארי של העמודות של A^T .
 כל $y \in \text{Im}(A^T)$ הוא צירוף ליניארי של העמודות של A^T .
 כל $y \in \text{Im}(A^T)$ הוא צירוף ליניארי של העמודות של A^T .

(4) $A^T A$ הוא מטריצה סימטרית (הוכח) ו- $(A^T A)^{-1}$ קיים.
 הראה ש- $\ker(A^T A) = \ker(A)$.

נניח ש- $x \in \ker(A^T A)$. אז $A^T A x = 0$.
 אז $x \in \ker(A)$.
 הפוך: נניח ש- $x \in \ker(A)$. אז $A x = 0$.
 אז $A^T A x = 0$.
 אז $x \in \ker(A^T A)$.

הוכח:

(א) $x \in \ker(A)$ אז $A x = 0$.
 אז $x \in \ker(A^T A)$.
 הפוך: נניח ש- $x \in \ker(A^T A)$. אז $A^T A x = 0$.
 אז $x \in \ker(A)$.

(ב) $w \in \ker(A)$ אז $A w = 0$.
 אז $w \in \ker(A^T A)$.
 אז $w \in \ker(A)$.
 הפוך: נניח ש- $w \in \ker(A^T A)$. אז $A^T A w = 0$.
 אז $w \in \ker(A)$.

(הצגה של \mathbb{R}^d כסדרה)

1.2

$\dim(V) = k$, $V \subseteq \mathbb{R}^d$ \rightarrow 5
 V היא תת-חלל ווקלי $\rightarrow (v_1, \dots, v_k)$ \rightarrow

$$P = \sum_{i=1}^k v_i v_i^t$$

(ד) P היא מטריצה סימטרית

$$P^t = (\sum v_i v_i^t)^t = \sum (v_i v_i^t)^t = \sum v_i v_i^t = P$$

\downarrow
 תכונה של
 מטריצה סימטרית

\downarrow
 תכונה של
 מטריצה סימטרית
 \rightarrow $v_i v_i^t$ היא מטריצה סימטרית
 \rightarrow סכום מטריצות סימטריות הוא מטריצה סימטרית

$$\begin{pmatrix} v_1 \\ \vdots \\ v_k \end{pmatrix}$$

$$\begin{pmatrix} v_1 \\ \vdots \\ v_k \end{pmatrix}$$

$$\begin{pmatrix} v_1 \\ \vdots \\ v_k \end{pmatrix}$$

$$x_1 x_1^t + x_2 x_2^t$$

$$\delta_{i,j} = \begin{cases} 1 & i=j \\ 0 & i \neq j \end{cases} \quad \text{gem 1.2}$$

(*) 5

→ n d n e j

$$P^2 = \sum_{i,j} v_i v_i^T v_j v_j^T = \sum_{i,j} v_i \langle v_i, v_j \rangle v_j^T$$

$$= \sum_{i,j} v_i \delta_{i,j} v_j^T = \sum_i v_i v_i^T = P$$

1 1L 0 m p le v i v j b zL p = p^2 m k : n s u m k

P

h n d n e j

→ sL p le h n d n e j v i v j

$$P v = \lambda v$$

$$P v = P^2 v = \lambda^2 v \quad (sL)$$

$$\lambda^2 v = \lambda v \quad (sL)$$

(h n d n e j) $\lambda \neq 0$ (sL)

$$\lambda = \lambda^2 \quad (sL)$$

$$\lambda \in \mathbb{R}$$

$$\Rightarrow \lambda \in \{0, 1\}$$

(h n d n e j) $v_j \forall j$ h n d n e j v i v j

$$P v_j = v_j = 1 \cdot v_j$$

(h n d n e j)

$$P v_j = \left(\sum_i v_i v_i^T \right) \cdot v_j = \sum_i v_i \langle v_i, v_j \rangle = \sum_i v_i \delta_{i,j} = v_j$$

5
: 1.2

: (2) 5

$$\forall v \in V \quad P v = v \quad : f.3$$

Let v_1, \dots, v_k be basis vectors for $V \rightarrow V$ is linear
($\sum \lambda_i v_i$)

$$\underline{v} = \sum_{i=1}^k \lambda_i v_i$$

$$\Rightarrow P \underline{v} = P \sum_{i=1}^k \lambda_i v_i$$

$$= \sum_{i=1}^k \lambda_i P v_i = \sum_{i=1}^k \lambda_i 1 \cdot v_i = \sum_{i=1}^k \lambda_i v_i = \underline{v}$$

Let v_i be basis vectors for V (linearly independent)
($\sum \lambda_i v_i = 0$ implies $\lambda_i = 0$)

$$(\text{if } \lambda_i \neq 0) \quad (2) \\ (P^2 = P)$$

$$(I - P)P = 0 \quad : f.3 \quad (3)$$

(2) linearly independent

~~else~~

1.3

6. כדי להשיג את הפתרון: $w = (X^T X)^{-1} X^T y$

הפתרון הוא $w = X^+ y$

$$w = V \Sigma^+ U^T y \stackrel{\text{def}}{=} X^+ y$$

$$\text{s.t. } \Sigma_{i,i}^+ = \begin{cases} \frac{1}{\Sigma_{i,i}} & \Sigma_{i,i} \neq 0 \\ 0 & \text{else} \end{cases}$$

הפתרון הוא $X^+ = (X^T X)^{-1} X^T$ כאשר X הפיכה מלאה

$$\begin{aligned} X X^T &= (U \Sigma V^T) (U \Sigma V^T)^T)^{-1} = (U \Sigma V^T V \Sigma^T U^T)^{-1} \\ &= (U \Sigma \Sigma^T U^T)^{-1} = (U^T)^{-1} (\Sigma \Sigma^T)^{-1} U^{-1} = U (\Sigma \Sigma^T)^{-1} U^T \end{aligned}$$

המשפט הזה נובע מ- $V V^T = I$, ולכן X הפיכה מלאה. אם $\Sigma^{-1} \Sigma^T$ אז הפתרון הוא $X^+ = (X^T X)^{-1} X^T$

$$\Rightarrow (X X^T)^{-1} X = U (\Sigma \Sigma^T)^{-1} U^T U \Sigma V^T = U \Sigma^{-1} \Sigma^T \Sigma V^T = U \Sigma^{-1} V^T$$

$\stackrel{\text{def}}{=} X^+$

~~$\dim \text{Im } A^T = \dim \text{Im } A$~~

דוגמה 1.3

$$R^d = \text{Sp}(x_1, \dots, x_m)$$

המטריצה $X^T X$: $\mathbb{R}^m \rightarrow \mathbb{R}^m$

$$\ker(X) = \ker(X^T X)$$

$$\ker(X) = \{0\} \iff \ker(X^T X) = \{0\} \iff \text{rank}(X^T X) = m$$

$$\iff X \text{ היא איזומורפיזם}$$

$$\iff \text{rank}(X) = m$$

1.3

8. טלם XX^T של המטריצה X וטלם $X^T X$ הסינגולריים.

$\Sigma \Sigma^T$ ו- $\Sigma^T \Sigma$ (סעיף 1.2).

טלם סינגולרי SVD: U, V

$$(*) \quad XX^T W = X Y$$

$$\Leftrightarrow U \Sigma \Sigma^T U^T W = U W V^T Y$$

הסינגולריים של $\Sigma \Sigma^T$ הם σ_i^2 ו- U הם הסינגולריים של $\Sigma \Sigma^T$.

הסינגולריים של $\Sigma \Sigma^T$ הם σ_i^2 ו- U הם הסינגולריים של $\Sigma \Sigma^T$.

הסינגולריים של $\Sigma \Sigma^T$ הם σ_i^2 ו- U הם הסינגולריים של $\Sigma \Sigma^T$.

$$\begin{bmatrix} w_1 \\ \vdots \\ w_r \\ \alpha_{r+1} \\ \vdots \\ \alpha_d \end{bmatrix}$$

הסינגולריים של $\Sigma \Sigma^T$ הם σ_i^2 ו- U הם הסינגולריים של $\Sigma \Sigma^T$.

הסינגולריים של $\Sigma \Sigma^T$ הם σ_i^2 ו- U הם הסינגולריים של $\Sigma \Sigma^T$.

$$\hat{W} = X^T Y = V \Sigma^T U^T Y$$

הסינגולריים של $\Sigma \Sigma^T$ הם σ_i^2 ו- U הם הסינגולריים של $\Sigma \Sigma^T$.

$$\left\| \begin{bmatrix} w_1 \\ \vdots \\ w_r \\ \alpha_{r+1} \\ \vdots \\ \alpha_d \end{bmatrix} \right\|_2 = \left\| \hat{W} \right\|_2 \leq \left\| \tilde{W} \right\|_2 = \left\| \begin{bmatrix} w_1 \\ \vdots \\ w_r \\ \alpha_{r+1} \\ \vdots \\ \alpha_d \end{bmatrix} \right\|_2$$

הסינגולריים של $\Sigma \Sigma^T$ הם σ_i^2 ו- U הם הסינגולריים של $\Sigma \Sigma^T$.